

최 석 재 *lingua@naver.com*



BERT 실습

구글 드라이브와 연결

- 런타임 > 런타임 유형 변경 > 하드웨어 가속기 > GPU 로 설정
- from google.colab import drive
- drive.mount('/content/gdrive')



Hugging Face 트랜스포머 설치

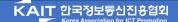
- !pip install transformers
- !pip install sacremoses

라이브러리 import

- import os
- import re
- import numpy as np
- from tqdm import tqdm
- import tensorflow as tf
- from transformers import *
- from tensorflow.keras.preprocessing.sequence import pad_sequences
- from tensorflow.keras.callbacks import EarlyStopping, ModelCheckpoint
- import pandas as pd
- import matplotlib.pyplot as plt

사용자 정의 시각화 함수

```
    def plot_graphs(history, string):
        plt.plot(history.history[string])
        plt.plot(history.history['val_'+string], '')
        plt.xlabel("Epochs")
        plt.ylabel(string)
        plt.legend([string, 'val_'+string])
        plt.show()
```



랜덤 시드 고정

- tf.random.set_seed(1111)
- np.random.seed(1111)

하이퍼파라미터 지정

- CLASS_NUMBER = 2
- BATCH_SIZE = 32
- NUM_EPOCHS = 2
- VALID_SPLIT = 0.2
- MAX_LEN = 40
- BERT_CKPT = '/content/gdrive/My Drive/pytest/data/KOR/naver_movie/bert_ckpt/'
- DATA_IN_PATH = '/content/gdrive/My Drive/pytest/data/KOR/naver_movie/data_in/'
- DATA_OUT_PATH = "/content/gdrive/My Drive/pytest/data/KOR/naver_movie/data_out/"

읽기와 쓰기 함수 정의 및 데이터 로딩

```
• def listToString(listdata):
    result = 'id\tdocument\tlabel\n'
    for data_each in listdata:
       if data_each:
           result += data_{each}[0] + "Wt" + data_{each}[1] + "Wt" + data_{each}[2] + "Wn"
    return result;

    def read_data(filename, encoding='cp949', start=0):

                                                         # 읽기 함수 정의
    with open(filename, 'r', encoding=encoding) as f:
        data = [line.split('Wt') for line in f.read().splitlines()]
        data = data[start:]
     return data

    def write_data(data, filename, encoding='cp949'):

                                                         # 쓰기 함수 정의
    with open(filename, 'w', encoding=encoding) as f:
       f.write(data)
```

• data_ratings = read_data(os.path.join(DATA_IN_PATH, "ratings_utf8_small.txt") , encoding='utf-8', start=1) # 자료 읽기

훈련데이터와 테스트데이터 분리

- from sklearn.model_selection import train_test_split
- ratings_train, ratings_test = train_test_split(data_ratings)
- ratings_train = listToString(ratings_train)
- ratings_test = listToString(ratings_test)
- write_data(ratings_train, os.path.join(DATA_IN_PATH, "ratings_train.txt"), encoding='utf-8')
- write_data(ratings_test, os.path.join(DATA_IN_PATH, "ratings_test.txt"), encoding='utf-8')



BERT 토크나이저 다운로드

tokenizer = BertTokenizer.from_pretrained(
 "bert-base-multilingual-cased",
 cache_dir=os.path.join(BERT_CKPT, "tokenizer"), do_lower_case=F
 alse)

BERT 토크나이저 연습 1

- test_sentence = "안녕하세요, 반갑습니다."
- encode = tokenizer.encode(test_sentence)
- token_print = [tokenizer.decode(token) for token in encode]
- print(encode)
- print(token_print)

BERT 토크나이저 연습 2

- kor_encode = tokenizer.encode("안녕하세요, 반갑습니다")
- eng_encode = tokenizer.encode("Hello world")
- kor_decode = tokenizer.decode(kor_encode)
- eng_decode = tokenizer.decode(eng_encode)
- print(kor_encode)
- print(eng_encode)
- print(kor_decode)
- print(eng_decode) [101, 9521, 118741, 35506, 24982, 48549, 117, 9321, 118610, 119081, 48345, 102] [101, 31178, 11356, 102] [CLS] 안녕하세요, 반갑습니다 [SEP]

[CLS] Hello world [SEP]

데이터 확인

- DATA_TRAIN_PATH = os.path.join(DATA_IN_PATH, "ratings_train.txt")
- DATA_TEST_PATH = os.path.join(DATA_IN_PATH, "ratings_test.txt")
- train_data = pd.read_csv(DATA_TRAIN_PATH, header = 0, delimiter
 = '₩t', quoting = 3)
- train_data = train_data.dropna()
- train_data.head()

	i d	document	label
0	7743368	박흥식영화 사랑해 말순씨 ***보면 장애우를 배려하지않는 저질 영화장애우가 성희롱이	0
1	10067386	안개 자욱한 밤하늘에 떠 있는 초승달 같은 영화.	1
2	4254270	성형부작용 같은 주인공 얼굴 때문에 집중이 안됨.;;;	0
3	530171	맥티어난의 최고 졸작품	0
4	9462634	어린 외계인역 하신분 귀엽네요ㅎ	1

스페셜 토큰 확인

- print(tokenizer.all_special_tokens, "₩n", tokenizer.all_special_ids)
- kor_encode = tokenizer.encode("안녕하세요, 반갑습니다. ")
- eng_encode = tokenizer.encode("Hello world")
- kor_decode = tokenizer.decode(kor_encode)
- eng_decode = tokenizer.decode(eng_encode)
- print(kor_encode)
- print(eng_encode)
- print(kor_decode)
- print(eng_decode)

```
['[UNK]', '[SEP]', '[PAD]', '[CLS]', '[MASK]']
[100, 102, 0, 101, 103]
[101, 9521, 118741, 35506, 24982, 48549, 117, 9321, 118610, 119081, 48345, 119, 102]
[101, 31178, 11356, 102]
[CLS] 안녕하세요, 반갑습니다. [SEP]
[CLS] Hello world [SEP]
```

사용자 정의 BERT 토크나이저 함수

```
encoded_dict = tokenizer.encode_plus(
    text = sent,
    add_special_tokens = True, # [CLS]와 [SEP] 추가
    max_length = MAX_LEN,
    pad_to_max_length = True,
    return_attention_mask = True
)

• input_id = encoded_dict['input_ids'] # 각 토큰을 인덱스로 변환
```

token_type_id = encoded_dict['token_type_ids'] # 문장이 1개일 경우 0, 2개일 경우 0과 1로 구분하여 생성

attention_mask = encoded_dict['attention_mask'] # 어텐션 마스크 생성

return input_id, attention_mask, token_type_id

def bert_tokenizer(sent, MAX_LEN):

훈련데이터 변환

- input_ids = []; attention_masks = []; token_type_ids = []; train_data_labels = []
 for train_sent, train_label in tqdm(zip(train_data["document"], train_data["label"]), total=len(train_data)): try:
 - input_id, attention_mask, token_type_id = bert_tokenizer(train_sent, MAX_LEN)
 - input_ids.append(input_id)
 - attention_masks.append(attention_mask)
 - token_type_ids.append(token_type_id)
 - train_data_labels.append(train_label)
- train_movie_input_ids = np.array(input_ids, dtype=int)
- train_movie_attention_masks = np.array(attention_masks, dtype=int)
- train_movie_type_ids = np.array(token_type_ids, dtype=int)
- train_movie_inputs = (train_movie_input_ids, train_movie_attention_masks, train_movie_type_ids)
- train_data_labels = np.asarray(train_data_labels, dtype=np.int32)



변환된 문장 확인

- input_id = train_movie_input_ids[1]
- attention_mask = train_movie_attention_masks[1]
- token_type_id = train_movie_type_ids[1]
- print(input_id)
- print(attention_mask)
- print(token_type_id)
- print(tokenizer.decode(input_id))

BERT 사전학습모델을 이용한 분류기 정의 – init()


- class TFBertClassifier(tf.keras.Model):
- def __init__(self, model_name, dir_path, num_class):
 super(TFBertClassifier, self).__init__()

```
self.bert = TFBertModel.from_pretrained(model_name, cache_dir=dir_path)
self.dropout = tf.keras.layers.Dropout(self.bert.config.hidden_dropout_prob)
self.classifier = tf.keras.layers.Dense(num_class, name="classifier")
```



BERT 사전학습모델을 이용한 분류기 정의 – call()

```
    def call(self, inputs, attention_mask=None, token_type_ids=None, training=False):
        outputs = self.bert(inputs, attention_mask=attention_mask, token_type_ids=token_type_ids)
        pooled_output = outputs[1]
        pooled_output = self.dropout(pooled_output, training=training)
        logits = self.classifier(pooled_output)
    return logits
```



BERT 모델 다운로드 및 분류기 실행

 cls_model = TFBertClassifier(model_name='bert-base-multilingual-cased', dir_path=os.path.join(BERT_CKPT, "model"), num_class=CLASS_NUMBER)



모델 컴파일

- optimizer = tf.keras.optimizers.Adam(3e-5)
- loss = tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True)
- metric = tf.keras.metrics.SparseCategoricalAccuracy('accuracy')
- cls_model.compile(optimizer=optimizer, loss=loss, metrics=[metric])

최적 모델 경로 생성

- model_name = "tf2_bert_naver_movie"
- earlystop_callback = EarlyStopping(monitor='val_accuracy', min_delta=0.0001,patience=2)
- checkpoint_path = os.path.join(DATA_OUT_PATH, model_name, 'weights.h5')
- checkpoint_dir = os.path.dirname(checkpoint_path)
- if os.path.exists(checkpoint_dir):
 print("{} -- Folder already exists ₩n".format(checkpoint_dir))
- else:

```
os.makedirs(checkpoint_dir, exist_ok=True)
print("{} -- Folder create complete ₩n".format(checkpoint_dir))
```


cp_callback = ModelCheckpoint(checkpoint_path, monitor='val_accuracy', verbose=1, save_best_only=True)
 cp_callback = ModelCheckpoint(checkpoint_path, monitor='val_accuracy', verbose=1, save_best_only=True)


최적 모델 학습

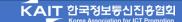
- history = cls_model.fit(train_movie_inputs, train_data_labels, epochs=NU M_EPOCHS, batch_size=BATCH_SIZE, validation_split = VALID_SPLIT, callbacks=[earlystop_callback, cp_callback])
- print(history.history)

Plotting Accuracy & Loss

- plot_graphs(history, 'accuracy')
- plot_graphs(history, 'loss')







테스트 데이터 확인

- test_data = pd.read_csv(DATA_TEST_PATH, header = 0, delimiter = '₩t', q uoting = 3)
- test_data = test_data.dropna()
- test_data.head()

label	document	i d	
1	그 반지의 제왕을 만든 피터 잭슨 ㅋㅋ 이런 영화을 찍었다는거 부터가 웃겼다. ㅋㅋ	9904263	0
0	삐질삐질;;	307000	1
1	내가 없어질 내인생. 제목을 참 잘 지었다.	8620641	2
0	굿	7553915	3
1	중3인데 일단 2까지봣다. 뭐 말할것도없다장국영 자살이 안타깝다	9339372	4

테스트 데이터 변환

- input_ids = []; attention_masks = []; token_type_ids = []; test_data_labels = []
- for test_sent, test_label in tqdm(zip(test_data["document"], test_data["label"])):
 try:
 input_id, attention_mask, token_type_id = bert_tokenizer(test_sent, MAX_LEN)
 input_ids.append(input_id)
 attention_masks.append(attention_mask)
 token_type_ids.append(token_type_id)
 test_data_labels.append(test_label)
- test_movie_input_ids = np.array(input_ids, dtype=int)
- test_movie_attention_masks = np.array(attention_masks, dtype=int)
- test_movie_type_ids = np.array(token_type_ids, dtype=int)
- test_movie_inputs = (test_movie_input_ids, test_movie_attention_masks, test_movie_type_ids)
- test_data_labels = np.asarray(test_data_labels, dtype=np.int32)

테스트 데이터 평가

- results = cls_model.evaluate(test_movie_inputs, test_data_label s, batch_size=BATCH_SIZE)
- print("test loss, test acc: ", results)




전체 data를 사용한 경우의 성능 (epoch 2)

epoch 1

epoch 2

• {'loss': [0.4132840633392334, 0.32376396656036377], 'accuracy': [0.8062252402305603, 0.8598774671554565], 'val_loss': [0.3805010914802551, 0.3470880091190338], 'val_accuracy': [0.8337944746017456, 0.8551285266876221]}




test loss, test acc: [0.34508270025253296, 0.8530341386795044]

전체 data를 사용한 경우의 성능 (epoch 3)

epoch 1 epoch 2 epoch 3

• {'loss': [0.40679264068603516, 0.3227856457233429, 0.26797860860824585], 'accuracy': [0.8123171925544739, 0.8600274920463562, 0.8875619769096375], 'val_loss': [0.3672649562358856, 0.3428157567977905, 0.3470034599304199], 'val_accuracy': [0.8386613130569458, 0.855361819267273, 0.8562285304069519]}



test loss, test acc: [0.3358493447303772, 0.8593543767929077]



검증데이터 성능 비교

	검증데이터 최고수치
ANN	0.832
Pre-embedding	0.762
Train data Embedding	0.823
SimpleRNN	0.821
LSTM	0.839
GRU	0.841
GRU 2층	0.837
BERT	0.859

용량 확보

- pytest > data > KOR > naver_movie 아래에 있는
- bert_ckpt 와 data_out 폴더를 삭제하여 용량을 확보한다
- 이 두 폴더는 다음 수행 시 자동 생성되며,
- 다음 수행 시 관련 파일은 덮어쓰기가 되므로 삭제하지 않아도 무방하다

